

Laboratorium 3

Apache Spark - platforma typu open-source do przetwarzania dużych ilości danych (typu big data) zbudowana dla szybkości, łatwości użycia i zaawansowanej analityki. Wykonuje obliczenia w pamięci w celu analizy danych w czasie rzeczywistym.

ZADANIA

Wykorzystując sparka napisz program, który implementuje algorytm k-średnich z uwzględnieniem dwóch miar: 'euclidean' oraz 'cosine'. Zmierz czasy działania obu wariantów klasteryzacji.

Plik wejściowy

- plik 3.txt zawiera zbiór danych, który posiada 4601 wektorów o 58 kolumnach

Parametry

- liczba klastrów k powinna wynosić 10

Wczytaj plik txt jako spark dataframe:

```
from pyspark.sql import SparkSession
spark = SparkSession.builder.appName("DataFrame").getOrCreate()
df = spark.read.text("3.txt")
df = df.selectExpr("split(value, ' ') as mycolumns")
```

Zrzutuj dane do "float":

<https://spark.apache.org/docs/latest/api/python/reference/pyspark.sql/api/pyspark.sql.Column.cast.html>

```
df = df.select([df['mycolumns'][i].cast("float").alias(f'data_{i}') for i in range(58)])
df.show()
```

Następnie:

- dokonaj wektoryzacji (VectorAssembler z pyspark.ml.feature),
vecAssembler = VectorAssembler(inputCols=df.columns, outputCol="features")
df_kmeans = vecAssembler.transform(df)
- użyj modelu kmeans do klasteryzacji danych (KMeans z pyspark.ml.clustering),
- przetrasformuj dane aby dołączyć wyniki z klasteryzacji,
- przedstaw końcowe wyniki (współczynnik sylwetki) oraz w formie graficznej (histogram).

<https://spark.apache.org/docs/latest/api/python/reference/api/pyspark.ml.clustering.KMeans.html>